

GUÍA DE TRABAJO

Proyecto 02 - Modelos de Clasificación

Curso: Minería de Datos / Ingeniería Civil en Bioinformática / Semestre 1-2026

1. Presentación general del proyecto

El Proyecto 02 tiene como propósito que cada estudiante desarrolle una experiencia completa de aplicación de técnicas de aprendizaje supervisado, específicamente en una tarea de clasificación, utilizando un set de datos real.

A diferencia de ejercicios más acotados, este proyecto busca integrar distintas etapas del proceso de minería de datos y machine learning: definición del problema, comprensión del contexto, análisis exploratorio, preparación de datos, implementación de modelos, evaluación comparativa, interpretación de resultados y selección justificada del mejor modelo.

Cada estudiante deberá trabajar con un set de datos validado por el profesor y deberá implementar distintos modelos de clasificación utilizando principalmente Python y la librería scikit-learn, junto con librerías como NumPy, Pandas y matplotlib. También se permitirá el uso de otras herramientas o librerías de machine learning, siempre que su uso sea pertinente, esté bien explicado y contribuya al desarrollo del proyecto.

El proyecto considera avances durante el semestre, un informe final y una presentación oral de resultados. Las actividades prácticas asociadas al proyecto no son recuperables, de acuerdo con las condiciones generales informadas para el Proyecto 02.

2. Objetivo general

Desarrollar, evaluar y comparar distintos modelos de clasificación sobre un set de datos real, identificando el modelo que presenta mejor desempeño para la tarea definida y justificando dicha selección en base a evidencia experimental, métricas de evaluación e interpretación crítica de los resultados.

3. Objetivos específicos

- Definir claramente una tarea de clasificación supervisada a partir de un set de datos real.
- Describir el contexto del problema y justificar su relevancia.
- Revisar antecedentes de trabajos similares, idealmente con el mismo set de datos o con problemas de clasificación comparables.
- Realizar un análisis exploratorio del set de datos.
- Identificar posibles problemas del dataset, tales como desbalance de clases, datos faltantes, atributos irrelevantes, alta dimensionalidad o posible maldición de la dimensionalidad.
- Preparar adecuadamente los datos para el entrenamiento y evaluación de modelos.
- Implementar distintos modelos de clasificación.
- Evaluar los modelos usando múltiples validaciones independientes.
- Reportar matrices de confusión, tasas de falsos positivos y métricas de desempeño.
- Analizar posibles situaciones de sobreajuste.
- Comparar los resultados obtenidos con antecedentes de trabajos similares.
- Seleccionar y justificar el mejor modelo para la tarea de clasificación definida.

4. Condiciones generales de trabajo

El proyecto será de carácter individual. Cada estudiante deberá seleccionar un tema de trabajo y un set de datos, los cuales deberán ser validados por el profesor antes de avanzar en el desarrollo completo del proyecto.

La implementación deberá realizarse principalmente en Python. Se espera el uso de las siguientes librerías:

- Pandas, para carga, manipulación y análisis de datos.
- NumPy, para operaciones numéricas.
- matplotlib u otras librerías equivalentes para visualización.
- scikit-learn, para implementación, entrenamiento, evaluación y comparación de modelos de clasificación.
- Librerías adicionales, como xgboost, cuando corresponda.

Los estudiantes deberán informar avances durante el desarrollo del proyecto. Estos avances permitirán corregir problemas metodológicos, validar decisiones de análisis y orientar mejoras específicas según la naturaleza de cada dataset.

Esta guía establece las exigencias generales del Proyecto 02. Sin embargo, dependiendo del set de datos utilizado, el profesor podrá solicitar análisis adicionales o ajustes metodológicos específicos, especialmente cuando existan problemas de desbalance de clases, alta dimensionalidad, bajo número de ejemplos, atributos complejos o resultados difíciles de interpretar.

5. Definición del problema de clasificación

Cada estudiante deberá describir claramente el problema de clasificación que abordará. Esta sección es fundamental, ya que permite comprender qué se busca predecir, por qué es relevante y cómo se relaciona el set de datos con la tarea de aprendizaje supervisado.

La descripción deberá incluir, al menos:

- Tema general del proyecto.
- Fuente del set de datos.
- Descripción general del problema.
- Variable objetivo o clase a predecir.
- Número de clases del problema.
- Significado de cada clase.
- Ejemplo concreto de lo que representa una instancia del set de datos.
- Número total de ejemplos disponibles.
- Número de ejemplos por clase.
- Número de atributos originales.
- Tipo de atributos: numéricos, categóricos, binarios, ordinales u otros.

Además, se deberá justificar la importancia del problema. Para ello, el estudiante deberá investigar brevemente el contexto general de la temática, incorporando antecedentes, cifras, aplicaciones o problemas asociados.

6. Revisión de antecedentes y trabajos similares

Cada estudiante deberá buscar información adicional sobre trabajos similares al problema abordado. Esta sección es obligatoria.

Idealmente, se deberán identificar estudios, artículos, reportes, notebooks o trabajos previos que hayan utilizado el mismo set de datos. Si esto no es posible, se deberán considerar trabajos con una temática similar, una tarea de clasificación equivalente o datasets comparables.

La revisión deberá responder preguntas como:

- ¿Se ha utilizado previamente este mismo set de datos?
- ¿Qué modelos de machine learning se han aplicado a problemas similares?
- ¿Qué métricas de evaluación fueron reportadas?
- ¿Qué resultados se obtuvieron?
- ¿Qué modelos tuvieron mejor desempeño?
- ¿Los resultados obtenidos en este proyecto son razonables en comparación con esos antecedentes?

No se espera una revisión bibliográfica extensa, pero sí una búsqueda suficiente que permita comparar y contextualizar los resultados propios del proyecto.

Cuando sea posible, se deberán reportar resultados de referencia, por ejemplo:

Trabajo o fuente	Dataset o problema	Modelos usados	Métricas reportadas	Principales resultados

Esta revisión no debe ser decorativa. Debe servir para interpretar los resultados propios y discutir si el desempeño obtenido es bajo, aceptable, competitivo o superior a lo reportado en trabajos similares.

7. Análisis exploratorio del set de datos

Cada estudiante deberá realizar un análisis exploratorio inicial del set de datos, retomando lo trabajado en el Proyecto 01. El objetivo de esta etapa es comprender la estructura, calidad y comportamiento general de los datos antes de entrenar modelos.

El análisis exploratorio deberá incluir, al menos:

- Dimensiones del dataset: número de filas y columnas.
- Descripción de las variables.
- Identificación de la variable objetivo.
- Tipos de datos.
- Resumen estadístico de atributos numéricos.
- Distribución de atributos relevantes.
- Distribución de las clases.
- Identificación de datos faltantes.
- Identificación de posibles valores atípicos.
- Visualizaciones relevantes.
- Comentarios sobre patrones iniciales observados.

En el caso de atributos categóricos, se deberá revisar la frecuencia de las categorías principales. En el caso de atributos numéricos, se deberán analizar rangos, medias, desviaciones estándar, valores extremos y posibles problemas de escala.

El EDA debe ayudar a justificar decisiones posteriores, tales como eliminación de variables, transformación de atributos, normalización, codificación de variables categóricas, tratamiento de datos faltantes o selección de métricas de evaluación.

8. Identificación de problemas del dataset

Además del análisis exploratorio general, cada estudiante deberá revisar explícitamente si el set de datos presenta problemas que puedan afectar el entrenamiento o evaluación de los modelos.

8.1. Desbalance de clases

Se deberá reportar el número y porcentaje de ejemplos por clase. Si una o más clases están subrepresentadas, el estudiante deberá discutir el posible impacto del desbalance en la evaluación de los modelos.

En presencia de desbalance, no será suficiente reportar solo accuracy. Se deberán analizar también métricas como precision, recall, F1-score, tasa de falsos positivos, matriz de confusión y, cuando corresponda, ROC/AUC.

El estudiante podrá considerar estrategias como:

- Uso de métricas más adecuadas para datos desbalanceados.
- Uso de `class_weight` en modelos que lo permitan.
- Submuestreo o sobremuestreo, si es pertinente.
- Técnicas como SMOTE, si se justifican adecuadamente.
- Análisis por clase, especialmente en problemas multiclase.

No todos los proyectos deberán aplicar técnicas de balanceo, pero todos deberán analizar si el desbalance existe y si puede afectar las conclusiones.

8.2. Alta dimensionalidad y posible maldición de la dimensionalidad

Si el número de atributos es muy alto respecto del número de ejemplos, el estudiante deberá discutir el posible efecto de la alta dimensionalidad en el desempeño de los modelos.

Esto es especialmente importante en modelos sensibles a la distancia o a la estructura del espacio de atributos, como KNN, SVM o algunos modelos lineales.

En estos casos, se podrá considerar:

- Selección de atributos.
- Eliminación de atributos irrelevantes o redundantes.
- Análisis de correlación.
- Reducción de dimensionalidad.
- Regularización.
- Comparación de modelos con y sin ciertas variables.

No es obligatorio aplicar técnicas avanzadas de reducción de dimensionalidad en todos los casos, pero sí se debe discutir si la dimensionalidad del dataset puede representar un problema metodológico.

9. Preparación de datos para machine learning

Antes de entrenar los modelos, cada estudiante deberá preparar los datos de forma adecuada. Las decisiones tomadas deberán ser explicadas en el informe.

Entre las acciones esperadas se incluyen:

- Separación entre variables predictoras X y variable objetivo y.
- Codificación de variables categóricas, si corresponde.
- Tratamiento de datos faltantes.
- Escalamiento o normalización de atributos cuando sea necesario.
- Eliminación o transformación de variables no útiles.
- Revisión de atributos redundantes o problemáticos.
- Preparación de datos de entrenamiento y prueba.

El estudiante deberá tener especial cuidado con el orden de las operaciones. Por ejemplo, si se realiza escalamiento, este debe ajustarse usando los datos de entrenamiento y luego aplicarse a los datos de prueba, evitando filtración de información desde el conjunto de prueba hacia el entrenamiento.

10. Modelos de clasificación a implementar

Cada estudiante deberá implementar y evaluar distintos modelos de clasificación. Como base mínima, se espera considerar los siguientes modelos:

1. K-Nearest Neighbors.
2. Árboles de Decisión.
3. Naive Bayes.
4. Random Forest.
5. Regresión Logística.
6. Support Vector Machine.
7. XGBoost.

La exclusión de alguno de estos modelos deberá estar debidamente justificada. En algunos casos, dependiendo del dataset, el profesor podrá solicitar modelos adicionales o permitir ajustes al conjunto de modelos evaluados.

La implementación deberá permitir comparar modelos de forma justa, usando las mismas particiones de entrenamiento/prueba y las mismas métricas principales.

11. Evaluación de hiperparámetros y configuraciones por modelo

No será suficiente entrenar una única versión de cada modelo. Cada estudiante deberá explorar configuraciones o hiperparámetros relevantes, de acuerdo con la naturaleza de cada algoritmo.

11.1. KNN

Se deberá evaluar el desempeño del modelo con distintos valores de k . Como referencia, se sugiere probar valores de $k = 1$ a $k = 20$, pudiendo extender hasta $k = 50$ si se considera necesario. Se espera presentar una tabla o gráfico que muestre cómo cambia el desempeño del modelo en función de k .

11.2. Árboles de Decisión

Se deberán comparar árboles con distintas configuraciones. Como mínimo, se espera analizar modelos con y sin control de complejidad. Se podrán modificar parámetros como `max_depth`, `min_samples_split`, `min_samples_leaf`, criterio de división y estrategias de poda o control de profundidad. Se deberá observar si árboles muy complejos presentan sobreajuste.

11.3. Naive Bayes

Se deberá justificar la variante de Naive Bayes utilizada según el tipo de atributos presentes en el dataset, por ejemplo Gaussian, Multinomial o Bernoulli Naive Bayes. Cuando corresponda, se deberán evaluar al menos dos alternativas razonables.

11.4. Random Forest

Se deberá evaluar el desempeño con distintos números de árboles. Como referencia, se sugiere probar 10, 20, 50, 100, 200 y 500 árboles. También se podrán analizar parámetros como profundidad máxima, número mínimo de ejemplos por hoja o número de atributos considerados en cada división.

11.5. Regresión Logística

Se deberá considerar la necesidad de escalar variables numéricas, especialmente si los atributos tienen distintas unidades o rangos. Se podrán analizar configuraciones relacionadas con regularización, parámetro C , número máximo de iteraciones y estrategia multiclase, si corresponde.

11.6. SVM

En el caso de SVM, se deberá prestar especial atención al escalamiento de variables. Se podrán analizar configuraciones como kernel lineal, kernel RBF, parámetro C y parámetro γ , cuando corresponda.

11.7. XGBoost

Para XGBoost, se deberán evaluar configuraciones básicas, tales como número de estimadores, profundidad máxima, tasa de aprendizaje y submuestreo, si corresponde. No se espera una optimización exhaustiva, pero sí una exploración razonable de configuraciones.

12. Estrategia mínima de evaluación experimental

La evaluación de modelos no deberá basarse en una única partición entrenamiento/prueba.

Cada estudiante deberá realizar, como mínimo, 10 validaciones independientes de tipo 80/20. Esto significa que se deberán generar 10 particiones distintas del set de datos, usando aproximadamente 80% de los datos para entrenamiento y 20% para prueba en cada repetición.

Para cada modelo y configuración relevante, se deberán calcular métricas de desempeño en cada una de las 10 validaciones. Luego se deberán reportar la media y desviación estándar de los resultados.

Una forma esperada de presentación es la siguiente:

Modelo	Accuracy promedio $\pm$ DE	Precision promedio $\pm$ DE	Recall promedio $\pm$ DE	F1-score promedio $\pm$ DE	AUC promedio $\pm$ DE
KNN					
Árbol de Decisión					
Naive Bayes					
Random Forest					
Regresión Logística					
SVM					
XGBoost					

Además, se deberá explorar cómo obtener los valores de desempeño de cada una de las validaciones realizadas. No será suficiente confiar únicamente en funciones que entregan un resumen automático de performance. El estudiante deberá ser capaz de mostrar los resultados individuales de las validaciones, al menos para los modelos principales.

13. Métricas de evaluación obligatorias

Cada estudiante deberá evaluar los modelos utilizando distintas métricas de desempeño. La selección de métricas deberá ser coherente con el problema abordado, especialmente si existe desbalance de clases.

Como mínimo, deberán reportarse:

- Accuracy.
- Precision.
- Recall.
- F1-score.
- Matriz de confusión.
- Tasa de falsos positivos.
- Tasa de verdaderos positivos o sensibilidad.
- ROC/AUC, cuando corresponda.

En problemas multiclase, el estudiante deberá indicar si las métricas se calcularon usando promedio macro, micro o weighted, y justificar brevemente la elección.

La matriz de confusión deberá ser presentada e interpretada, no solo incluida como una tabla o figura. El estudiante deberá explicar qué clases se confunden con mayor frecuencia y qué implicancias tiene esto para el problema estudiado.

La tasa de falsos positivos deberá calcularse e interpretarse. En problemas binarios, puede expresarse como:

$$\text{FPR} = \text{FP} / (\text{FP} + \text{TN})$$

donde FP corresponde a falsos positivos y TN corresponde a verdaderos negativos. En problemas multiclase, se deberá explicar cómo se calculó o interpretó esta tasa para cada clase o mediante un enfoque promedio.

14. Análisis de sobreajuste

Cada estudiante deberá analizar si alguno de los modelos evaluados presenta evidencia de sobreajuste.

Para esto, se recomienda comparar el desempeño en entrenamiento y prueba. Si un modelo presenta resultados muy altos en entrenamiento, pero considerablemente más bajos en prueba, se deberá discutir la posibilidad de sobreajuste.

El análisis de sobreajuste deberá estar fundamentado en resultados concretos. No será suficiente afirmar que “el modelo está sobreajustado” sin mostrar evidencia.

Se podrán usar elementos como:

- Comparación de accuracy en entrenamiento y prueba.
- Comparación de F1-score en entrenamiento y prueba.
- Variación de desempeño al modificar hiperparámetros.
- Profundidad excesiva en árboles de decisión.
- Valores de k muy bajos en KNN.
- Diferencias importantes entre validaciones.
- Desempeño inestable entre las 10 repeticiones 80/20.

También se deberá discutir si algún modelo presenta subajuste, es decir, bajo desempeño tanto en entrenamiento como en prueba.

15. Comparación y selección del mejor modelo

Una vez evaluados los modelos, cada estudiante deberá seleccionar cuál considera el mejor modelo para la tarea de clasificación definida.

La selección no deberá basarse únicamente en accuracy. Se deberá considerar:

- Métricas promedio.
- Desviación estándar de las métricas.
- Matriz de confusión.
- Tasa de falsos positivos.
- Recall o sensibilidad, especialmente si una clase es más importante.
- F1-score en casos de desbalance.
- AUC, cuando corresponda.
- Estabilidad del modelo entre validaciones.
- Posible sobreajuste.
- Interpretabilidad del modelo.
- Comparación con trabajos similares.

El informe deberá justificar claramente por qué se selecciona un modelo y no otro. En algunos casos, el mejor modelo no será necesariamente el que tenga mayor accuracy, sino aquel que entregue un mejor equilibrio entre desempeño, estabilidad e interpretación para el problema analizado.

16. Comparación con antecedentes externos

Los resultados obtenidos deberán compararse con la información encontrada en trabajos similares.

El estudiante deberá discutir preguntas como:

- ¿Los resultados obtenidos son parecidos a los reportados previamente?
- ¿Son mejores o peores?
- ¿Qué diferencias metodológicas podrían explicar esas diferencias?
- ¿Se usaron las mismas métricas?
- ¿Se usó el mismo set de datos o uno similar?
- ¿El problema tenía el mismo número de clases?
- ¿El tratamiento del desbalance fue similar?
- ¿Se usaron técnicas de validación comparables?

Esta comparación debe ser crítica y prudente. No se debe afirmar que un modelo es mejor que el de la literatura si las condiciones experimentales no son equivalentes.

17. Informe final

El informe final deberá dar cuenta del trabajo completo realizado. Se sugiere la siguiente estructura:

1. Título del proyecto.
2. Resumen breve.
3. Introducción y contexto del problema.
4. Definición del problema de clasificación.
5. Revisión de trabajos similares.
6. Descripción del set de datos.
7. Análisis exploratorio de datos.
8. Identificación de problemas del dataset.
9. Preparación de datos.
10. Modelos implementados.
11. Configuraciones e hiperparámetros evaluados.
12. Diseño experimental de evaluación.
13. Resultados por modelo.
14. Matrices de confusión y análisis de errores.
15. Análisis de falsos positivos y falsos negativos.
16. Análisis de sobreajuste.
17. Comparación con trabajos similares.
18. Selección justificada del mejor modelo.
19. Conclusiones.
20. Limitaciones y posibles mejoras futuras.
21. Referencias.
22. Anexos, si corresponde.

El informe debe estar escrito de manera clara y ordenada. No debe limitarse a pegar capturas de código o salidas de Python. Los resultados deben ser explicados e interpretados.

18. Presentación oral final

Cada estudiante deberá presentar oralmente los principales resultados de su proyecto. La presentación deberá resumir los aspectos más importantes del trabajo realizado.

Se recomienda que la presentación incluya:

1. Problema de clasificación.
2. Dataset utilizado.
3. Distribución de clases.
4. Principales hallazgos del EDA.
5. Modelos implementados.
6. Estrategia de evaluación.
7. Resultados comparativos.
8. Matrices de confusión principales.
9. Análisis de falsos positivos y falsos negativos.
10. Discusión sobre sobreajuste.
11. Comparación con trabajos similares.
12. Mejor modelo seleccionado y justificación.
13. Conclusiones.

La presentación no debe centrarse en mostrar código, sino en explicar las decisiones metodológicas, los resultados obtenidos y la interpretación del desempeño de los modelos.

19. Criterios generales de evaluación

La evaluación del Proyecto 02 considerará tanto el desarrollo técnico como la capacidad de análisis e interpretación de resultados.

Criterio	Aspectos esperados
Definición del problema	Claridad de la tarea de clasificación, variable objetivo, clases y relevancia del problema.
Revisión de antecedentes	Búsqueda de trabajos similares, resultados previos y comparación crítica.
Descripción del dataset	Número de ejemplos, atributos, clases, balance/desbalance y calidad de datos.
Análisis exploratorio	Limpieza, visualizaciones, análisis de distribuciones y patrones relevantes.
Preparación de datos	Codificación, escalamiento, manejo de datos faltantes y separación correcta de datos.
Implementación de modelos	Uso correcto de modelos de clasificación, incluyendo KNN, DT, NB, RF, Regresión Logística, SVM y XGBoost.
Evaluación de hiperparámetros	Exploración razonable de configuraciones por modelo.
Diseño experimental	Al menos 10 validaciones independientes 80/20 y reporte de medias y desviaciones estándar.
Métricas de desempeño	Accuracy, precision, recall, F1-score, matriz de confusión, tasa de falsos positivos y AUC cuando corresponda.
Análisis de sobreajuste	Comparación entrenamiento/prueba y discusión fundamentada.
Comparación de modelos	Selección justificada del mejor modelo según múltiples criterios.
Interpretación de resultados	Discusión crítica de errores, limitaciones y coherencia con trabajos similares.
Informe final	Claridad, orden, redacción, tablas, gráficos y referencias.
Presentación oral	Capacidad de síntesis, explicación de resultados y defensa metodológica.

20. Consideraciones finales

El Proyecto 02 no busca únicamente obtener un modelo con buen desempeño, sino desarrollar un análisis completo y fundamentado de una tarea de clasificación real.

Por ello, se espera que cada estudiante sea capaz de explicar qué problema está resolviendo, por qué es relevante, cómo preparó los datos, qué modelos evaluó, cómo los comparó, qué errores cometieron los modelos y por qué seleccionó finalmente una alternativa como la más adecuada.

El uso de código es necesario, pero no suficiente. La calidad del proyecto dependerá de la capacidad de combinar implementación, análisis, interpretación y comunicación clara de resultados.

Esta guía constituye la base general del Proyecto 02. En función del avance de cada estudiante y de las características específicas de cada set de datos, se podrán solicitar ajustes o análisis adicionales durante el desarrollo del trabajo.